Relatório Técnico (Parte 1) - Fase 6 (Projeto Cardio IA)

Grupo:

- *Vitor Lopes Romão*
- *Gabriela da Cunha Rocha*
- *Gabrielle Halasc*
- *Gustavo Segantini Rossignolli*

Introdução

Este é um relatório técnico que foi requisitado para atividade da Fase 6 do curso de Inteligência Artificial da FIAP. Nesta fase, na primeira parte da atividade, foi proposto o desafio de um **modelo preditivo supervisionado** utilizando uma base de dados voltada à **cardiologia**. Foi utilizado uma base com dados fictícios de cardiologia que foi encontrada no site Kaggle, que foi proposto na Fase 1 deste projeto. Para conferir o dataset utilizado, você pode seguir este link que irá te direcionar para a página da base de dados fictícia.

O documento consiste em 6 partes: incluindo a **introdução** até a **reflexão sobre possíveis limitações ou melhorias do projeto**.

1. Decisões do modelo

Sobre as decisões do modelo, a primeira delas foi a escolha do algoritmo **Gradient Boosting**, por ser o algoritmo que teve uma maior eficácia dentre os outros testes. Além desse algoritmo, foi testado o algoritmo de Random Forest e Regressão Logística.

Já para o teste de hiperparâmetros do modelo, foi decidido utilizar a técnica **GridSearchCV**. Conhecida por ser uma ótima prática ao **testar os hiperparâmetros de um algoritmo**, essa técnica permite a definição de uma grade de parâmetros, e quando testada, dentro dessa grade, ela irá entender e decidir qual parâmetro que se adequou da melhor maneira possível através das métricas de **score F1**, dessa forma, otimizando o modelo.

A escolha de F1 como métrica de avaliação e não acurácia se dá por conta do **equilíbrio** entre a precisão e a revocação usando a média harmônica, garantindo que o modelo seja eficiente na detecção da classe minoritária sem gerar excesso de **falsos positivos**. Como a acurácia mede a proporção total de acertos, se por um acaso o dataset tiver 98% de pessoas consideradas não saudáveis, ele dará a entender que, ao identificar uma pessoa

saudável, o modelo estaria acertando por simplesmente classificar todos como doentes, o que resultaria em um modelo inútil na prática.

Por fim, a decisão de limpar o dataset logo ao iniciar o projeto baseia-se em critérios fisiológicos fundamentais, já que a pressão sistólica **deve ser maior** que a diastólica. Normalmente, a pressão sistólica deve ser algo entre *60-250 mmHg* e a diastólica entre *40-200 mmHg*. Já na questão de peso e altura, para um senso em "comum" deste projeto, foi definido altura entre *140 cm* e *220 cm* e o peso entre *30 kg* a *200 kg*..

2. Justificativa de escolha do algoritmo

Após a utilização do recurso de **validação cruzada** (*cross_val_score*) da biblioteca Scikit Learn, onde houve uma comparação de três algoritmos, a justificativa da escolha do algoritmo **Gradient Boosting** se deu por conta das métricas de avaliação serem melhores comparado aos algoritmos de **Random Forest** e **Regressão Logística**. Como este modelo prevê a variável *"pico_risco"* (se um paciente tem risco cardiológico ou não, segundo as informações da sua saúde), também foi utilizado a métrica **AUC-ROC**, uma métrica de desempenho para modelos de classificação binária.

3. Interpretação das métricas obtidas

As métricas aplicadas para avaliação do modelo foram: precision, recall, F1-Score, AUC-ROC e acurácia.

Neste contexto da base de cardiologia, podemos entender cada métrica da seguinte forma:

- **Acurácia:** de tudo que predisse, quanto acertou?
- **Precision:** quando acusa risco, com que frequência está certo?
- **Recall:** dos doentes reais, quantos o modelo encontrou?
- **F1-Score:** equilíbrio entre Precision e Recall.
- **AUC-ROC:** poder discriminativo independente do limiar.

Logo abaixo, podemos ver o gráfico **AUC-ROC**:

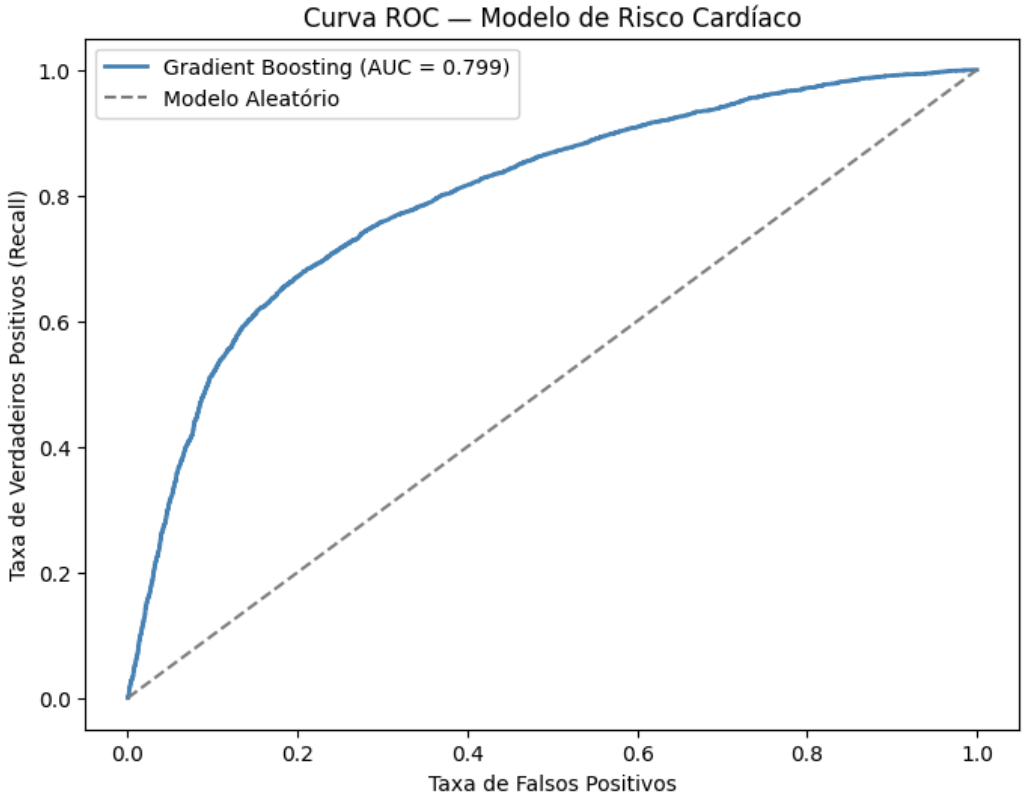

Esse gráfico trás uma perspectiva da curva sobre a taxa de verdadeiros positivos, tendo uma assertividade de **79%**.

No próximo gráfico, trás uma visão sobre as importâncias das features que o modelo se baseia para fazer suas predições. A principal variável é *"ap_hi"*.

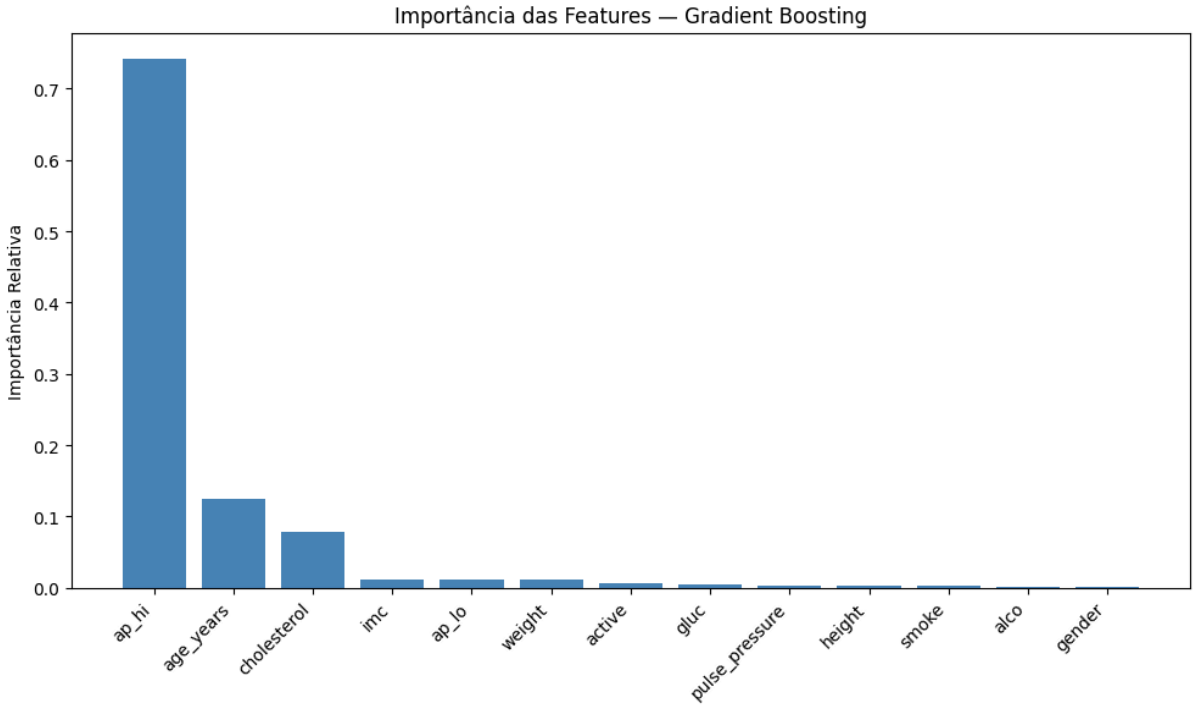

4. Análise dos resultados da matriz de confusão

O gráfico de matriz de confusão serve para **comparar os dados de rótulos reais dos dados com as previsões feitas pelo modelo**, onde a **diagonal principal** (esquerda para direita) representa os acertos do modelo de **Verdadeiros Positivos** e **Verdadeiro Negativos**. Já na diagonal secundária (direita para esquerda), vemos os **Falsos Negativos** e **Falsos Positivos**. Logo abaixo, temos o gráfico que foi gerado durante o projeto:

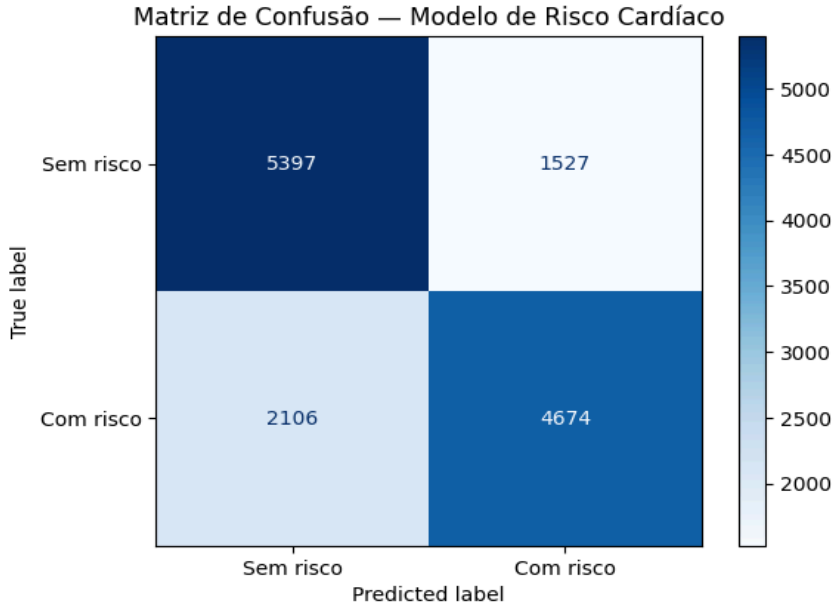

Podemos ver claramente que o modelo se sobressaiu melhor na diagonal principal, logo tendo uma taxa de acertos maior que o modelo previu. Olhando para os números, podemos ver as seguintes métricas:

```
Acurácia: 0.7349

--- Relatório Completo ---
              precision    recall  f1-score   support

   Sem risco       0.72      0.78      0.75      6924
   Com risco       0.75      0.69      0.72      6780

    accuracy                           0.73     13704
   macro avg       0.74      0.73      0.73     13704
weighted avg       0.74      0.73      0.73     13704
```

Quando o modelo acusou que não havia risco, a **precisão (Precision)** foi de **72%**. Já dos pacientes que realmente não tinham risco no dataset, o modelo identificou corretamente o **Recall** foi de **78%**. Seguindo na mesma linha de raciocínio, quando o modelo acusou que havia risco, a **precisão (Precision)** foi de **75%**. E dos pacientes que

realmente tinham risco no dataset, o **Recall** foi de **69%** — o ponto mais crítico do modelo, pois significa que 31% dos pacientes em risco real não foram identificados.

Interpretação das métricas: O modelo atingiu **73% de acurácia** com F1 de **0.72** para a classe de risco. O Recall de **0.69** indica que o modelo identifica corretamente **69%** dos pacientes em risco real — margem que pode ser melhorada com mais feature engineering ou dados adicionais.

Limitações: Os hiperparâmetros ótimos encontrados pelo Grid Search coincidiram com os valores padrão do sklearn, sugerindo que o teto do modelo está nos dados e não na configuração. Um dataset com variáveis adicionais (histórico familiar, exames laboratoriais) provavelmente elevaria esse teto.

5. Reflexão sobre possíveis limitações ou melhorias

Viés de dados nas variáveis comportamentais: Variáveis como tabagismo e consumo de álcool apresentaram importância preditiva **próxima de zero** no modelo. Isso não reflete irrelevância clínica, mas sim um forte desbalanceamento no dataset: apenas 8,8% dos registros correspondem a fumantes e 5,3% a consumidores de álcool. Com tão pouca variação nessas colunas, o modelo não encontra padrão suficiente para aprendê-las como discriminadoras de risco. Em projetos futuros, técnicas como **SMOTE** (geração de amostras sintéticas da classe minoritária) ou o parâmetro class_weight='balanced' poderiam mitigar esse efeito.

Dependência excessiva de uma única feature: A variável ap_hi (pressão sistólica) concentrou **74%** da importância total do modelo, segundo a métrica de ganho de pureza. Isso é clinicamente coerente, porém representa um risco operacional: qualquer erro de medição da pressão sistólica compromete diretamente a qualidade da predição. Uma versão mais robusta do modelo deveria distribuir melhor a importância entre múltiplas variáveis.

Multicolinearidade entre features derivadas: A variável pulse_pressure (pressão de pulso), criada como diferença entre **ap_hi** e **ap_lo**, apresentou importância negativa na análise de **Permutation Importance**. Isso ocorre porque ela é matematicamente derivada de ap_hi, que já está presente no modelo, gerando redundância. Em versões futuras, features com correlação acima de 0,85 entre si devem ser avaliadas antes do treinamento para evitar esse tipo de ruído.

Recall de 69% para a classe de risco: O modelo ainda deixa escapar 31% dos pacientes em risco real — uma limitação relevante em contexto clínico. Melhorias

possíveis incluem enriquecimento do dataset com variáveis clínicas adicionais (histórico familiar, exames laboratoriais) e ajuste do limiar de classificação para priorizar o Recall em detrimento da Precision, conforme o critério de risco aceitável definido pelo domínio médico.